Film Insight

Analiza opinii tekstowych i ocen liczbowych filmów

Od języka recenzji do wzorców oceniania

Raport eksploracyjny • 29 października 2026

RECENZJE	OCENY	UŻYTKOWNICY
2000	100 836	610

Cel projektu

Zbadać, jakie cechy odróżniają pozytywne i negatywne recenzje filmów oraz jakie wzorce ujawniają oceny użytkowników. Projekt łączy analizę tekstu z analizą liczbową w ramach wspólnej tematyki kina.

Zakres tego raportu

Źródła i jakość dwóch rzeczywistych zbiorów, analiza eksploracyjna, statystyka opisowa, pytania badawcze oraz pilotaż klasyfikacji sentymentu. Klasteryzacja, transformery i pełna ewaluacja są zaplanowane na dalsze etapy.

Zespół i podział odpowiedzialności

Imię i nazwisko	ID	Zakres prac
Mykola Kostiuk	72256	Lider zespołu: koordynacja projektu i metodologia, integracja kodu i wyników, redakcja końcowa raportu oraz zarządzanie repozytorium GitHub.
Ivan Vlasenko	71732	Dane tekstowe Cornell: przygotowanie i kontrola jakości, analiza długości i słownictwa recenzji, wizualizacje oraz opis wyników analizy tekstowej.
Yehor Lysenko	71886	Dane liczbowe MovieLens: przygotowanie i kontrola jakości, analiza ocen, gatunków i popularności filmów, wizualizacje oraz opis wyników.
Ivan Saltykov	71657	Pilotaż modeli NLP: przygotowanie podziału trening-test, porównanie LR i SVM, metryki i analiza błędów, panel wyników oraz weryfikacja odtwarzalności.

Repozytorium GitHub: https://github.com/n3wcastlE/film-insight-ml

01 / Pytania i projekt badania

P1. Język recenzji

Czy długość i słownictwo recenzji różnią się pomiędzy klasą pozytywną i negatywną? Hipoteza robocza: rozkłady długości nie są identyczne. Sprawdzenie: mediany, histogramy, test Manna-Whitneya i wielkość efektu.

P2. Struktura ocen

Jak wyglądają rozkład ocen oraz zależność średniej oceny filmu od liczby ocen? Sprawdzenie: statystyki opisowe, wykres rozrzutu i korelacja rang Spearmana.

P3. Gatunki

Jak różnią się średnie oceny między gatunkami? Analiza opisowa obejmuje gatunki z co najmniej 1000 ocen; uwzględnia wielogatunkowość filmów i zależność obserwacji.

P4. Predykcja

Czy TF-IDF z regresją logistyczną i liniowym SVM przewyższa klasyfikator większościowy? Miary: accuracy i macro-F1 na wydzielonym zbiorze testowym.

P5. Dalszy etap

Czy metody nienadzorowane wyodrębnią stabilne grupy preferencji, a transformer poprawi klasyfikację sentymentu? Odpowiedź wymaga kolejnych eksperymentów.

Dwie perspektywy, dwa zbiory

Jednostką obserwacji w Cornell jest recenzja, a w MovieLens - pojedyncza ocena użytkownika dla filmu. Zbiory nie są połączone rekord po rekordzie. Nie można na ich podstawie wyliczyć bezpośredniej zgodności tekstu recenzji z oceną MovieLens ani porównywać proporcji sentymentu jak populacyjnych ocen widowni.

02 / Dane i kontrola jakości

Cecha	Cornell polarity v2.0	MovieLens latest-small
Pochodzenie	Bo Pang i Lillian Lee; rzeczywiste recenzje filmowe [1]	GroupLens, University of Minnesota; rzeczywiste oceny użytkowników [2]
Rozmiar	2000 recenzji; po 1000 neg i pos	100836 ocen; 610 użytkowników; 9742 filmów w katalogu
Zmienne	tekst, klasa neg/pos, identyfikator pliku	userId, movieId, rating, timestamp; tytuł i gatunki
Zakres	Cały korpus v2.0; bez podpróbkowania	Wszystkie rekordy archiwum small; bez podpróbkowania
Przetwarzanie	Tekst już wstępnie przetworzony przez autorów; tokenizacja regex do długości	Połączenie ocen z filmami po movieId; rozdzielenie list gatunków; rok z tytułu

Cornell: 0 pustych tekstów i 0 dokładnych duplikatów. MovieLens: 0 braków w ratings.csv, 0 identycznych wierszy, 0 powtórzeń par użytkownik-film i 0 ocen bez filmu w katalogu. Roku wydania nie udało się odczytać dla 13 tytułów; nie uzupełniano go sztucznie.

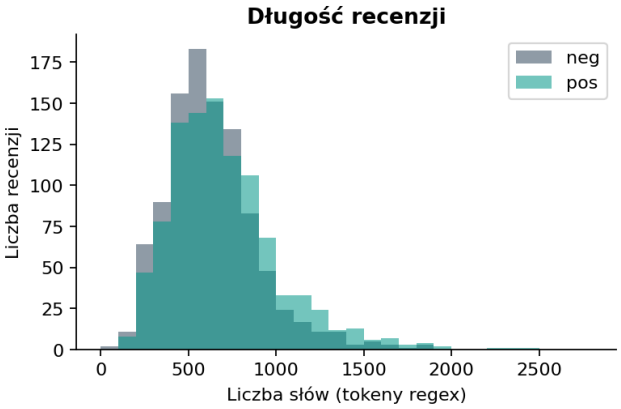
Okres ocen MovieLens (UTC): 1996-03-29 - 2018-09-24. W analizie ocen występuje 9724 filmów; sam katalog zawiera również pozycje bez oceny.

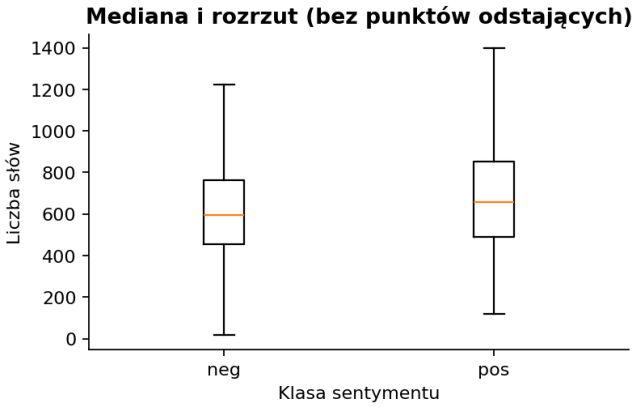
Pochodzenie, licencje i odtwarzalność

Archiwa pobrano z oryginalnych serwisów 29.10.2026. Ich rozmiary i SHA-256 zapisano w results/summary.json. Dołączono oryginalne README. MovieLens pozwala na niekomercyjną redystrybucję na warunkach swojego README. Cornell wymaga wskazania wersji i cytowania źródła; prawa do oryginalnych tekstów pozostają przy ich właścicielach. Skrypt download_data.py pobiera Cornell bezpośrednio od autorów.

MovieLens latest-small to zbiór rozwojowy, a nie stabilny benchmark badawczy. W projekcie edukacyjnym zamrażamy konkretny pobrany plik za pomocą jego sumy kontrolnej.

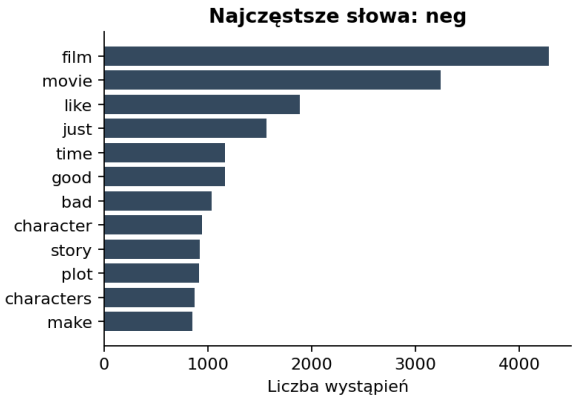
03 / Tekst: długość i słownictwo

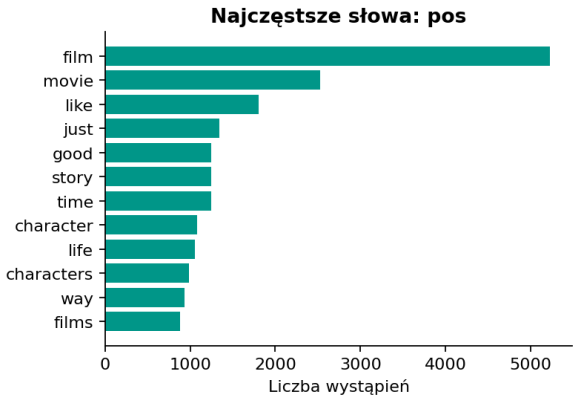




Klasa	N	Średnia słów	Mediana	Odch. stand.
neg	1000	631,66	595,50	265,45
pos	1000	705,12	659,00	317,07

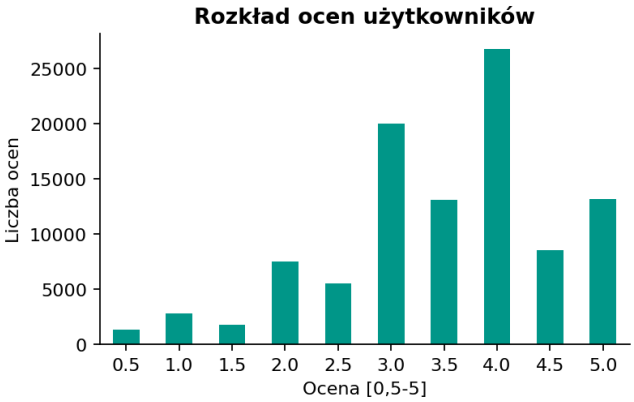
Test Manna-Whitneya: U = 565127, p = 4.57e-07; rangowa wielkość efektu (pos względem neg) = 0,13. Efekt jest niewielki mimo małej wartości p. Test porównuje rozkłady/rangi; interpretacja jako różnicy median wymaga założeń o ich kształcie. Wynik jest eksploracyjny; zależność recenzji tego samego autora lub filmu może wpływać na wnioskowanie.

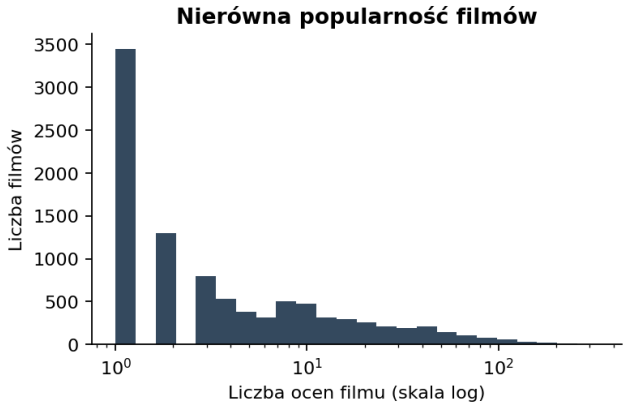




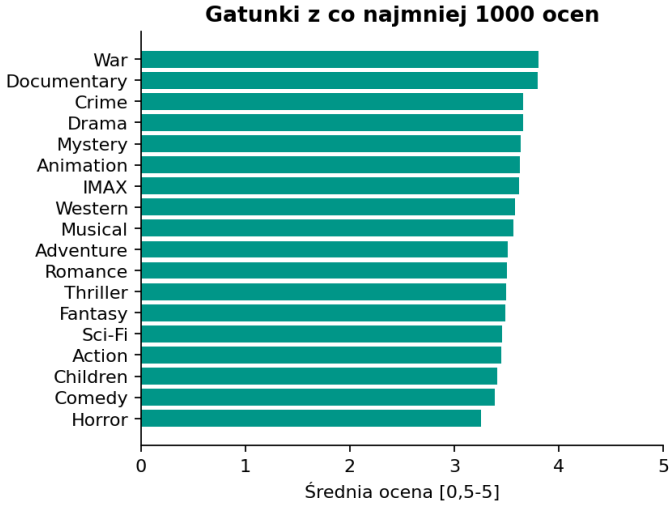
Źródło wykresów: pełny Cornell polarity v2.0. Liczba słów: tokeny regex \b\w+\b. Słownictwo: CountVectorizer, angielskie stopwords, min_df=5, maks. 20 000 cech. Częstość słowa nie dowodzi jego przyczynowego wpływu na sentyment.

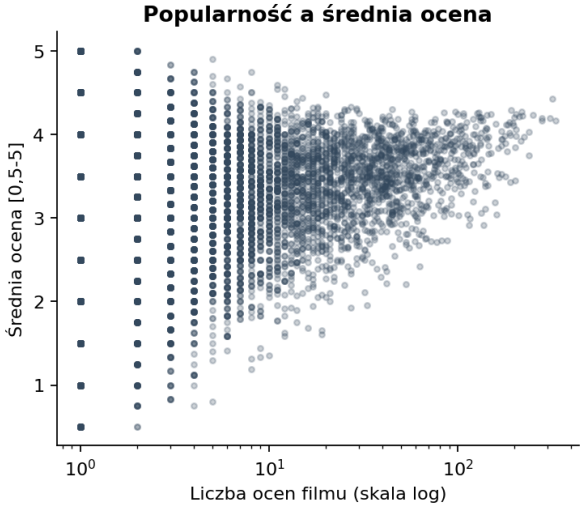
04 / Oceny: rozkład i popularność





Średnia ocena wynosi 3,50, mediana 3,50, a odchylenie standardowe 1,04 na skali 0,5-5. Mediana liczby ocen przypadających na film to 3,00. Rozkład popularności jest nierówny, dlatego średnia oparta na kilku ocenach jest znacznie mniej stabilna niż średnia oparta na setkach ocen.





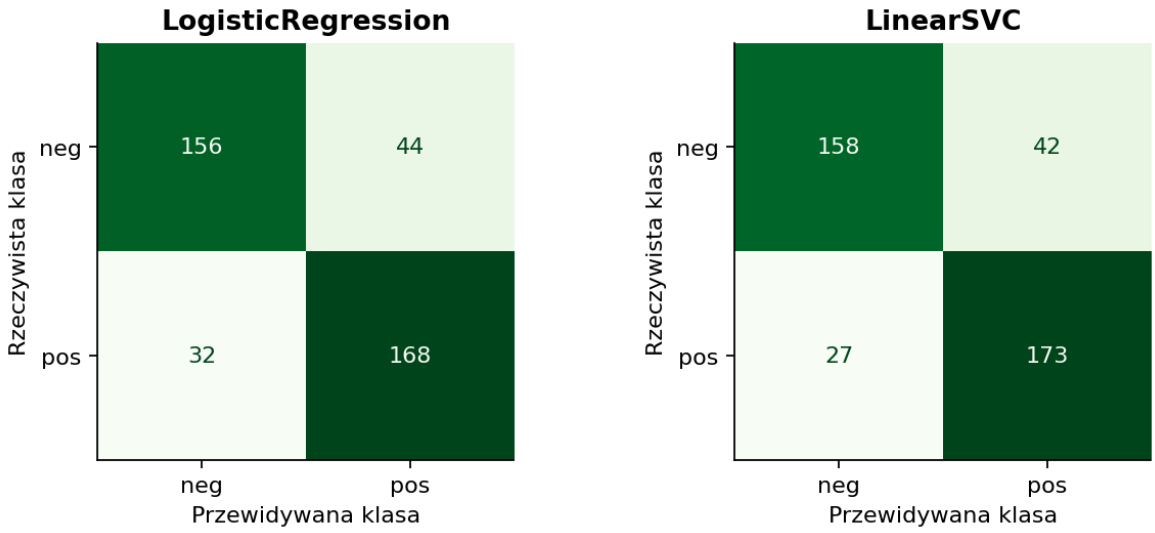
Korelacja Spearmana pomiędzy liczbą ocen a średnią oceną filmu: rho = 0,04, p = 9.45e-05. Zależność jest bardzo słaba mimo małej wartości p; nie wnioskujemy o przyczynowości. Każdy film jest tu jedną obserwacją; małe liczby ocen zwiększają szum średnich.

Źródło: MovieLens latest-small, wszystkie oceny z okresu 1996-2018. Gatunki: średnia ważona liczbą ocen; film wielogatunkowy występuje w kilku grupach. Grupy nie są niezależne, podobnie jak oceny jednego użytkownika. Różnice średnich mogą wynikać ze składu użytkowników, filmów i okresu; nie interpretujemy ich jako efektu gatunku.

05 / Pilotaż uczenia nadzorowanego

Wstępnie porównano dwa modele: regresję logistyczną i liniowy SVM. Po usunięciu dokładnych duplikatów tekstu zastosowano jeden podział stratyfikowany 80/20: 1600 recenzji treningowych i 400 testowych, random_state=42. TF-IDF jest dopasowywany wyłącznie na treningu wewnątrz Pipeline: unigramy i bigramy, min_df=2, do 50 000 cech, angielskie stopwords.

Model	Accuracy	Macro-F1
Klasa większościowa	50,00%	nie oceniano
LogisticRegression	81.00%	0.8098
LinearSVC	82.75%	0.8273



Interpretacja i granice pilotażu

Macierze pomyłek pokazują osobno poprawne i błędne rozpoznania obu klas. Oba modele mają ustalone parametry; nie prowadzono strojenia ani wyboru parametrów na teście. Jest to punkt odniesienia dla dalszych prac, a nie ostateczny ranking metod. Różnic na pojedynczym podziale nie traktujemy jako dowodu przewagi statystycznej.

Dokładne duplikaty nie przekraczają granicy trening-test. Podział nie jest jednak grupowany po autorze lub filmie; współdzielone źródła i podobne recenzje mogą zawyżać wynik. W kolejnym etapie należy wykorzystać identyfikatory źródeł, jeśli da się je wiarygodnie odtworzyć, oraz walidację krzyżową na części treningowej. Cornell ma sztucznie zrównoważone klasy: nie odzwierciedla częstości opinii w całej widowni.

06 / Wnioski i dalsze eksperymenty

W badanym korpusie mediana długości recenzji pozytywnych jest wyższa. Wielkość efektu i wykresy są potrzebne do oceny znaczenia tej różnicy; sama mała wartość p nie wystarcza. Tekstowe modele bazowe zostały rzeczywiście uruchomione i ocenione na odłożonych danych.

W MovieLens oceny i popularność filmów są nierównomierne. Interpretując rankingi gatunków, trzeba uwzględnić liczbę ocen i powtarzających się użytkowników. Oba zbiory umożliwiają analizę opinii o kinie, lecz nie stanowią wspólnej reprezentatywnej próby.

Następny eksperyment	Uzasadnienie i ewaluacja
Nadzorowane: LR i liniowy SVM	Rozszerzyć wykonany pilotaż o walidację krzyżową na treningu i analizę błędów; test zachować do oceny końcowej.
Nienadzorowane: KMeans i NMF	KMeans: segmentacja użytkowników na podstawie profili preferencji po redukcji wymiaru. NMF: nieujemne tematy recenzji TF-IDF. Ocena: stabilność klastrów, silhouette i interpretowalność tematów; parametry dobierane bez etykiet testowych.
Transformer: DistilBERT	Porównać z klasycznymi modelami na tym samym podziale; dokumentować źródło modelu i możliwość kontaktu z benchmarkiem podczas pretreningu.
Interfejs	Dołączony lokalny panel pozwala przeglądać wyniki. Kolejny etap: predykcja sentymentu nowych tekstów i analiza segmentów.

Odtworzenie wyników

Python 3.11 lub nowszy. Polecenia: pip install -r requirements.txt; python src/download_data.py; python src/analyze.py; python src/build_report.py. Panel: python src/serve.py, następnie http://localhost:8765. Szczegóły oraz sprawdzone wersje bibliotek znajdują się w README.md i requirements-lock.txt.

Źródła

[1] Pang, B., Lee, L. (2004). A Sentimental Education: Sentiment Analysis Using Subjectivity Summarization Based on Minimum Cuts. ACL. Cornell polarity dataset v2.0. https://www.cs.cornell.edu/people/pabo/movie-review-data/

[2] Harper, F. M., Konstan, J. A. (2015). The MovieLens Datasets: History and Context. ACM TiiS 5(4), 19. https://doi.org/10.1145/2827872. Dane i warunki: https://files.grouplens.org/datasets/movielens/ml-latest-small-README.html